

Análise de Séries Temporais e Predição:

Serviços Automotivos MecaniQa

Autor: <Daniel Queiroga Santana Martins>
<João Roberto Santos Cardoso>
<Pedro Henrique Freitas Couto>
<Gabriel De Souza Nascimento>
<Victor Tadeu Araújo Augusto>
<André Walter Menezes>

Itabuna, 2026

Agenda

O objetivo dessa apresentação é analisar o histórico de serviços da MecaniQa, tratar falhas nos dados e aplicar modelos de previsão usando séries temporais.

1. Item 1:

Preparação dos Dados:
Carregamento e
Interpolação Linear.

2. Item:

Tratamento de Outliers:
Aplicação do método de
amplitude interquartil
(IQR).

3. Item:

Decomposição Sazonal:
Análise de tendência,
sazonalidade e resíduos.

4. Item:

Modelagem Preditiva:
Comparação entre
histórico e modelos de
médias móveis.

5. Item:

Considerações Finais:
Resultados obtidos e
próximos passos.

Visão Geral e Tratamento de Dados




- Estruturação temporal e organização cronológica do dataset da MecaniQa.
- Tratamento de falhas com interpolação linear e correção de outliers pelo método IQR.

Tratamento de Outliers (IQR)




- Itens para discussão:

- Método de amplitude interquartil (IQR) para identificar anomalias.
- Substituição de valores extremos (picos) pela mediana da série.
- Comparação: Dados originais (com falhas) vs. Série estabilizada.



Decomposição Sazonal


- Itens para discussão:
 - Separação da série temporal em Tendência, Sazonalidade e Resíduos.
 - Identificação de padrões de repetição (janela de 30 dias).
 - Comportamento isolado da demanda por Manutenções de Motor.



Gerenciamento Preditivo (Média Móvel)



- Itens para discussão:
 - Aplicação do Modelo Naive (Ingênuo) como base de comparação.
 - Suavização da demanda através de Médias Móveis (7 e 30 dias).
 - Projeção do volume de trocas de óleo para auxiliar no planejamento da oficina.



Considerações finais



- **A importância do tratamento de dados:** A aplicação do método IQR para remover outliers e a interpolação estabilizaram a série temporal, evitando que anomalias distorcessem a análise.
- **Valor para o negócio:** A transição de dados brutos para projeções preditivas permite que a MecaniQa antecipe a necessidade de peças (como óleo e filtros) e planeje melhor a escala da equipe de mecânicos.
- **Eficácia das Médias Móveis:** Os modelos de média móvel (especialmente o de 7 e 30 dias) mostraram-se muito úteis para suavizar a volatilidade diária, oferecendo uma linha de base sólida em comparação ao modelo Naive (Ingênuo).
- **Identificação de padrões estruturais:** A decomposição sazonal permitiu separar claramente o que é tendência de crescimento/queda e o que é repetição sazonal, facilitando o entendimento da demanda da oficina.

Referências

- **Pandas:** Equipe de Desenvolvimento do Pandas. *pandas: powerful Python data analysis toolkit*. Disponível em: pandas.pydata.org.
- **Statsmodels:** Seabold, S., & Perktold, J. *statsmodels: Econometric and statistical modeling with python*. (Módulo `tsa.seasonal`). Disponível em: statsmodels.org.
- **Visualização de Dados:** Documentações oficiais das bibliotecas Matplotlib (Hunter, J. D.) e Seaborn (Waskom, M.).